МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет ИТМО»

Отчет по практике
Тема:

Адаптивная токенизация для языковых моделей ДНК

Выполнил:
Широкий Николай Игоревич

Научный руководитель:
Макаров Илья Андреевич

Санкт-Петербург
2026

СОДЕРЖАНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ 3

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ 4

ВВЕДЕНИЕ 6

1 ОБЗОР ЛИТЕРАТУРЫ 9
1.1 Теоретические основы ДНК для проектирования токенизатора 9
1.2 Языковые модели ДНК 10
1.2.1 Архитектуры на основе Transformer 10
1.2.2 Модели на основе State Space Models 11
1.2.3 Гибридные модели 11
1.2.4 Общие тенденции 12
1.3 Методы токенизации ДНК-последовательностей 13
1.3.1 Посимвольная токенизация 13
1.3.2 Токенизация k-мерами 13
1.3.3 BPE-токенизация 13
1.3.4 Ограничения статических подходов 14
1.4 Адаптивная и обучаемая токенизация 15
1.4.1 Адаптивная токенизация в NLP 15
1.4.2 Адаптивная токенизация ДНК 16
1.4.3 Сравнительный анализ подходов 17
1.5 Бенчмарки для оценки геномных языковых моделей 17
1.6 Выводы по главе 1 18

2 ОПИСАНИЕ ПРЕДЛАГАЕМОГО МЕТОДА 19
2.1 Общая архитектура 19
2.2 Инициализация представлений 19
2.2.1 Входная последовательность и матрица вложений 19
2.2.2 Позиционное кодирование 20
2.2.3 Контекстное обогащение 20
2.2.4 Обработка reverse complement 20

2.3 Гейтированная оценка границ ... 21
2.3.1 Функция оценки слияния ... 21
2.3.2 Температурная модуляция ... 21
2.3.3 Интеграция биологических приоров ... 22
2.4 Механизм рекурсивного слияния ... 23
2.4.1 Задача выбора пар ... 23
2.4.2 Дифференцируемый выбор через dDP ... 23
2.4.3 Формирование объединённых представлений ... 24
2.5 Позиционное кодирование после слияния и декодирование ... 24
2.5.1 Позиционное кодирование спанов ... 24
2.5.2 Основная модель ... 25
2.5.3 Каузальный декодер с перекрёстным вниманием ... 25
2.6 Функция потерь ... 26
2.6.1 Основная функция потерь ... 26
2.6.2 Регуляризаторы ... 26
2.6.3 Итог ... 27
2.7 Стратегия обучения ... 27
2.7.1 Оптимизатор ... 27
2.7.2 Поэтапное обучение ... 27
2.7.3 Подготовка данных ... 28
2.8 План экспериментальной оценки ... 28
2.8.1 Базовые модели ... 28
2.8.2 Абляционное исследование ... 28
2.8.3 Метрики ... 28
2.8.4 Анализ выученной токенизации ... 29
2.9 Вычислительная сложность ... 29
2.10 Выводы по главе 2 ... 29

ЗАКЛЮЧЕНИЕ ... 31

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ ... 31

А РУКОВОДСТВО ПО ИСПОЛЬЗОВАНИЮ ШАБЛОНА ... 38

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

BPE - Byte Pair Encoding (кодирование байтовых пар)

BPN - Bits Per Nucleotide (бит на нуклеотид)

CR - Compression Ratio (коэффициент сжатия)

dDP - Differentiable Dynamic Programming (дифференцируемое динамическое программирование)

GBST - Gradient-Based Subword Tokenization

GPU - Graphics Processing Unit (графический процессор)

LM - Language Model (языковая модель)

MLP - Multilayer Perceptron (многослойный перцептрон)

NTP - Next Nucleotide Prediction (предсказание следующего нуклеотида)

PE - Positional Encoding (позиционное кодирование)

PWM - Position Weight Matrix (позиционная весовая матрица)

RC - Reverse Complement (обратный комплемент)

RoPE - Rotary Positional Embedding

SSM - State Space Model (модель пространства состояний)

TF - Transcription Factor (транскрипционный фактор)

TR - Token Ratio (доля токенов к длине исходной последовательности)

ВКР - выпускная квалификационная работа

ДНК - дезоксирибонуклеиновая кислота

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

Backbone - основная часть модели, выполняющая главное преобразование последовательности токенов

BPN (bits per nucleotide) - количество бит на нуклеотид, используемое как языковая метрика качества

Compression ratio (CR) - коэффициент сжатия последовательности, вычисляемый как $1 - N/L$

caQTL - вариант генома, статистически ассоциированный с изменением доступности хроматина

cCREs - candidate cis-regulatory elements, кандидатные цис-регуляторные элементы по аннотациям ENCODE

ClinVar - база данных клинически интерпретированных генетических вариантов

dsQTL - вариант генома, ассоциированный с изменением чувствительности к DNase I

EPDnew - Eukaryotic Promoter Database, база аннотированных эукариотических промоторов

GENCODE - референсная аннотация генов и транскриптов для геномов человека и мыши

JASPAR - открытая база мотивов связывания транскрипционных факторов (PWM-профили)

LINE - long interspersed nuclear elements, класс длинных повторяющихся ретротрансп

Hard-forward / soft-backward - схема обучения, в которой прямой проход использует жёсткие решения, а обратный проход использует мягкую релаксацию

k-мер - подпоследовательность ДНК фиксированной длины k

NTP (next nucleotide prediction) - задача предсказания следующего нуклеотида по предшествующему контексту

phastCons - phylogenetic hidden Markov model conservation scores, количественная оценка эволюционной консервативности нуклеотидных позиций

SINE - short interspersed nuclear elements, класс коротких повторяющихся ретротранс

Alu - наиболее распространённое у приматов семейство SINE-повторов

Мотив - короткий консервативный паттерн в ДНК, связанный с функциональным элементом

Промотор - участок ДНК, где инициируется транскрипция гена

Энхансер - регуляторный участок ДНК, усиливающий транскрипцию, часто на удалении от промотора

Накопительное состояние токена - дополнительное представление, агрегирующее историю предыдущих слияний токена

Нуклеотид - мономерная единица ДНК (аденин A, тимин T, цитозин C, гуанин G)

Обратный комплемент - последовательность, полученная заменой каждого нуклеотида комплементарным и разворотом в обратном направлении

TFBS - transcription factor binding site, сайт связывания транскрипционного фактора

Спан - непрерывный диапазон позиций в исходной последовательности, покрытый одним токеном после слияния

Token ratio (TR) - отношение числа токенов после сжатия к длине исходной последовательности, вычисляемое как N/L

Токенизация - процесс разбиения входной последовательности на дискретные единицы (токены) для обработки моделью

Токенизатор - модуль, преобразующий входную последовательность в последователь токенов

Функция потерь - целевая функция, минимизируемая в процессе обучения модели

ВВЕДЕНИЕ

За последние годы методы глубокого обучения получили широкое распространение в задачах геномики, в том числе в форме языковых моделей ДНК (DNA Language Models, DNA LM). В рамках данного подхода нуклеотидные последовательности используются в качестве корпуса для самосупервизионного обучения, после чего полученные представления применяются при решении прикладных задач, связанных с предсказанием регуляторных элементов, оценкой эффектов вариантов и функциональной аннотацией генома. Существенный вклад в развитие направления внесли модели HyenaDNA [1], DNABERT-2 [2], Caduceus [3], Nucleotide Transformer [4] и Evo [5]; обобщающий обзор состояния области представлен в [6].

Вместе с тем одной из ключевых нерешённых проблем остаётся токенизация входной последовательности. До подачи данных в модель ДНК-последовательность должна быть разбита на дискретные единицы. На практике в геномике для этого традиционно применяются посимвольное разбиение (один нуклеотид — один токен), фиксированные k-меры и алгоритм BPE [7], заимствованный из задач обработки естественного языка. Общей особенностью указанных схем является их статический характер: границы токенов определяются заранее и не адаптируются к локальной структуре конкретного участка генома.

Данная постановка ограничивает качество модели, поскольку геномная последовательность функционально неоднородна. Регуляторные элементы (промоторы — участки инициации транскрипции, энхансеры — удалённые усилители транскрипции, сайты связывания транскрипционных факторов (transcription factor binding sites, TFBS)) обычно локализованы в коротких участках, где критична точная позиционная информация. При этом межгенные регионы и повторяющиеся элементы, включая Alu (семейство SINE, short interspersed nuclear elements) и LINE (long interspersed nuclear elements), занимают около 45% генома человека [8] и в среднем содержат меньшую функциональную нагрузку. Использование фиксированных k-меров приводит к произвольному разрезанию мотивов в зависимости от

сдвига окна, а BPE ориентирован на частотность встречаемости подстрок, а не на их биологическую роль, вследствие чего повторяющиеся регионы получают преимущество при сжатии [9]. В работах Vishniakov и др. [10] и Eapen [11] показано, что выбор токенизатора оказывает заметное влияние на качество моделей и в ряде задач сопоставим по значимости с выбором архитектуры.

Начиная с 2024 года наблюдается рост числа исследований по обучаемой токенизации. В геномике модель MxDNA [12] реализует адаптивность через смесь свёрточных экспертов, а BioToken [13] демонстрирует, что даже ограниченное использование биологической структуры при построении токенов может улучшать результаты на прикладных задачах. В смежной области NLP также получены близкие выводы: модели Byte Latent Transformer [14] и MegaByte [15] подтверждают эффективность адаптивных и иерархических схем сегментации. Вместе с тем в рассмотренных работах отсутствует единая постановка, одновременно включающая рекурсивное слияние, дифференцируемое DP и интеграцию биологических приоров; разработка данной комбинации составляет центральную задачу настоящего исследования.

Целью настоящей работы является разработка метода адаптивной токенизации ДНК-последовательностей, основанного на рекурсивном гейтированном слиянии с интеграцией биологических приоров, и оценка его влияния на качество предобучения и решения задач геномики.

Для достижения цели поставлены следующие задачи:

1) проанализировать существующие методы токенизации ДНК и выявить их ограничения;
2) разработать архитектуру адаптивного токенизатора на основе рекурсивного гейтированного слияния с дифференцируемым динамическим программированием и интеграцией биологических приоров (оценки консервативности, мотивы транскрипционных факторов);
3) интегрировать разработанный метод в языковую модель ДНК с каузальным декодером, обеспечивающим предсказание на уровне нуклеотидов без утечки информации из будущего;
4) провести экспериментальную оценку на бенчмарке DART-Eval [16] в

сравнении с существующими методами.

В качестве объекта исследования выступают языковые модели для нуклеотидных последовательностей ДНК.

В качестве предмета исследования рассматриваются методы адаптивной токенизации ДНК-последовательностей для повышения качества геномных языковых моделей.

Научная новизна работы. Предложена архитектура адаптивного токенизатора на основе рекурсивного гейтированного слияния с дифференцируемым DP через log-semiring relaxation [17] — это позволяет оптимизировать границы токенов непрерывно при сохранении ограничения непересечения. В функцию оценки слияния интегрированы биологические приоры: оценки консервативности phastCons [18] и позиционные весовые матрицы JASPAR [19]. Функция потерь объединяет NTP с четырьмя регуляризаторами — сжатия, энтропии решений, RC-согласованности и разнообразия длин спанов. Помимо этого, в модуль слияния введено накопительное состояние токенов — учёт истории предыдущих операций слияния при принятии последующих решений.

Разработанный токенизатор реализован на Python/PyTorch [20] и встраивается в существующие пайплайны предобучения DNA LM как модуль — без переработки основной архитектуры. Прикладной критерий приемлемости сжатия зафиксирован явно: сравнение с BPE по token ratio (TR) и ΔBPN на одной выборке.

Структура работы включает введение, две главы, заключение, список использованных источников и приложение. В первой главе представлен обзор геномных языковых моделей, подходов к токенизации и существующих бенчмарков. Во второй главе описаны предлагаемый метод адаптивной токенизации, его архитектурные компоненты, функция потерь, стратегия обучения и план экспериментальной оценки.

1 ОБЗОР ЛИТЕРАТУРЫ

Настоящая глава охватывает три направления, на пересечении которых находится данное исследование: геномные языковые модели, методы токенизации ДНК и бенчмарки для оценки их качества.

1.1 Теоретические основы ДНК для проектирования токенизатора

При разработке токенизатора для ДНК критично учитывать, что биологическая последовательность не является однородной строкой символов. В отличие от классических NLP-корпусов, соседние участки генома могут различаться по функциональной нагрузке на порядки. Для токенизации это означает, что единое фиксированное правило разбиения не всегда согласуется с реальной структурой данных.

Полная референсная последовательность человека (T2T-CHM13) показывает масштаб задачи: речь идёт о миллиардах нуклеотидов с большим структурным разнообразием [21]. В результате геномной аннотации [8] было зафиксировано, что около 45% последовательности составляют повторяющиеся элементы, включая Alu (SINE) и LINE. С инженерной точки зрения это создаёт асимметрию: одни регионы требуют более детального представления, тогда как в других допустимо более агрессивное сжатие.

Регуляторный контроль опирается не только на сигналы вблизи промотора, но и на дальние enhancer–promoter взаимодействия, работающие на расстояниях в десятки тысяч пар оснований [22]. Токенизатор, который дробит регуляторные мотивы ради компактности, теряет именно тот уровень разрешения, где эти взаимодействия проявляются.

JASPAR [19] содержит позиционные весовые матрицы (PWM) для более 2000 транскрипционных факторов; ENCODE cCREs [23] фиксирует кандидатные цис-регуляторные элементы в масштабе генома; GENCODE [24] задаёт опорную аннотацию генов и экзонов. Для задачи токенизации это важно тем, что аннотации позволяют проверять, совпадают ли выученные границы спанов с биологически осмысленными границами.

Дополнительный сигнал дают эволюционные ограничения. Консервативные

элементы по межвидовым выравниваниям [18] обычно отражают функционально значимые участки, а резкие переходы уровня консервативности часто соответствуют смене функционального режима — и могут быть кандидатами на границы токенов.

Наконец, при проектировании токенизатора необходимо учитывать направленность и двуцепочечную природу ДНК. Порядок нуклеотидов в направлении $5' \rightarrow 3'$ биологически значим и связан с асимметриями мутационного процесса [25], тогда как многие регуляторные сигналы должны корректно интерпретироваться и на комплементарной цепи. В совокупности эти свойства формируют теоретические требования к современному токенизатору: контекстная адаптивность, сохранение функциональных границ, поддержка длинного контекста и согласованность относительно reverse complement.

Указанные биологические предпосылки задают критерии, по которым далее анализируются архитектуры геномных языковых моделей и существующие схемы токенизации.

1.2 Языковые модели ДНК

Языковые модели ДНК обучаются на нуклеотидных последовательностях в режиме самосупервизии и формируют представления, которые затем можно использовать для задач геномики [6; 26]. Геном человека содержит порядка $3{,}1 \times 10^9$ пар оснований [21], причём значительная часть функциональной информации скрыта в некодирующих регионах. Языковые модели позволяют извлекать эту информацию из данных без явных меток.

1.2.1 Архитектуры на основе Transformer

Transformer [27], изначально разработанный для NLP, в короткие сроки был адаптирован для задач геномики.

DNABERT [28] — одна из первых моделей, применивших BERT к ДНК. Она работает с перекрывающимися k-мерами ($k = 3, \ldots, 6$) в режиме MLM. Фиксированные k-меры привязывают модель к одному масштабу, а словарь растёт как 4^k. DNABERT-2 [2] решает это заменой k-меров на BPE: токены получаются переменной длины, плюс появляется возможность обучаться на мультивидовых данных.

Иной масштаб демонстрирует Nucleotide Transformer [4]: $2{,}5 \times 10^9$

параметров, последовательности более чем 3000 видов, неперекрывающиеся 6-меры. Масштаб помогает на прикладных задачах, однако ограничение фиксированных 6-меров сохраняется: границы k-меров по-прежнему не совпадают с функциональными границами в геноме.

GROVER [29] обучается на человеческом геноме с BPE и посимвольной инициализацией. Примечательно, что выученный BPE-словарь частично отражает биологически значимые подстроки — хотя сам BPE оптимизирует частотность, а не биологию.

1.2.2 Модели на основе State Space Models

Принципиальное ограничение Transformer — квадратичная сложность по длине последовательности. State Space Models (SSM) [30] дают линейную $O(L)$, что критично в задачах геномики, где длины в 10^5–10^6 нуклеотидов не являются редкостью.

HyenaDNA [1] построен на архитектуре Hyena (длинные свёртки) и обрабатывает до 10^6 нуклеотидов за раз, причём посимвольно — каждый нуклеотид выступает в качестве отдельного токена. Это снимает вопрос о произвольных границах разбиения, но создаёт другую проблему: очень длинные входные последовательности требуют специализированной архитектуры.

Caduceus [3] дополняет SSM двунаправленностью и RC-эквивариантностью. ДНК является двуцепочечной молекулой, и многие функциональные элементы (мотивы TF, промоторы) работают на обеих цепях; RC-эквивариантная архитектура гарантирует, что представления прямой и комплементарной цепей связаны фиксированным преобразованием — данное свойство является сильным индуктивным смещением, которое большинство моделей не учитывает.

Evo [5] и Evo 2 [31] — масштабирование SSM до 7×10^9 параметров на геномах всех доменов жизни. Evo 2 использует StripedHyena с окном до $1{,}6 \times 10^5$ нуклеотидов и умеет генерировать синтетические последовательности с биологически правдоподобными свойствами.

1.2.3 Гибридные модели

HybriDNA [32] комбинирует блоки Transformer и Mamba-2 [33]. Данная идея ранее уже рассматривалась, однако в этой работе она адаптирована

к геномике: посимвольная модель с меньшим числом параметров, чем у аналогов, достигает конкурентных результатов. Логика гибридной архитектуры следующая: Transformer-блоки хорошо моделируют локальные взаимозависимости через полный self-attention, тогда как Mamba-2 обрабатывает длинный контекст линейно. Чередование позволяет не терять ни локальную, ни дальнюю зависимость — модель учитывает и ближайший контекст, и удалённые энхансеры без полной цены $O(L^2)$.

Особенность работы AlphaGenome [34] от DeepMind — это сама решаемая задача: предсказание эффектов регуляторных вариантов от нуклеотидного до хромосомного масштаба. Принципиальная сложность здесь в том, что одна точечная мутация в регуляторном элементе может одновременно менять доступность хроматина, экспрессию нескольких генов и профиль контактов хромосом. Предсказывать все эти эффекты единой моделью с одного входа — иная постановка по сравнению с классификацией фиксированных окон.

1.2.4 Общие тенденции

При рассмотрении перечисленных моделей как единой траектории развития области можно выделить несколько устойчивых тенденций.

Контекстное окно растёт непрерывно: 512 нуклеотидов в ранних версиях DNABERT — и 10^6 в HyenaDNA. Это не случайно: взаимодействия энхансер–промотор [22] работают на расстояниях в десятки тысяч пар оснований, и модель, видящая только короткий контекст, часто не может корректно учитывать регуляторный сигнал.

Следует отметить, что ряд наиболее сильных результатов — HyenaDNA, Caduceus, Evo — получены при посимвольной токенизации, а не k-мерах или BPE. Это косвенно говорит о том, что фиксированные методы разбиения формируют ограничение качества, которое сложно преодолеть масштабом. Посимвольная токенизация потолка такого рода не создаёт, но платить приходится вычислительной ценой: длина последовательности напрямую определяет стоимость — $O(L^2)$ для Transformer или $O(L)$ для SSM, но с большим постоянным множителем.

Кроме того, в работах [9; 10] показано, что выбор токенизации существенно влияет на качество и недостатки токенизатора не всегда компенсируются более сильной архитектурой. В связи с этим рассматривается вопрос о возможности создания обучаемой схемы токенизации, адаптирующейся

к содержанию последовательности в процессе совместного обучения с моделью.

1.3 Методы токенизации ДНК-последовательностей

1.3.1 Посимвольная токенизация

Посимвольная схема предполагает, что каждый нуклеотид (A, T, C, G) кодируется как отдельный токен. Данный подход обеспечивает минимальный словарь ($|V| = 4$ плюс специальные токены), отсутствие артефактов разбиения и максимальное разрешение; на нём основаны HyenaDNA [1], Caduceus [3] и Evo [5]. Ключевым недостатком данного подхода является то, что длина входа равна длине ДНК, что определяет вычислительную сложность $O(L^2)$ для Transformer или $O(L)$ для SSM.

Помимо этого, посимвольная токенизация полностью устраняет артефакт frame-shift, характерный для k-мерных схем, при котором один и тот же мотив разбивается по-разному в зависимости от стартовой позиции окна. Поскольку каждый нуклеотид всегда представлен одним токеном вне зависимости от контекста, данным фактором, вероятно, объясняется то, что HyenaDNA и Caduceus на ряде задач зондирования обходят более крупные k-мерные модели даже при меньшем числе параметров [10].

1.3.2 Токенизация k-мерами

Разбиение на подстроки длины k сокращает вход в k раз при неперекрывающейся схеме. Использовалось в DNABERT ($k = 3, \ldots, 6$) [28] и Nucleotide Transformer ($k = 6$) [4].

При использовании данного подхода возникают две трудности: словарь растёт как 4^k (при $k = 6$ — 4096 токенов, при $k \geq 8$ матрица вложений становится существенно ресурсоёмкой), а границы k-меров произвольны — один и тот же биологический мотив разбивается по-разному в зависимости от стартовой позиции разбиения.

1.3.3 BPE-токенизация

BPE [7] итеративно сливает наиболее частотные пары символов, строя словарь переменной длины. В геномных моделях это используется в DNABERT-2 [2] и GROVER [29]; обзор мотивации этого выбора с точки зрения проектирования фундаментальных моделей см. в [35]. Переменная

длина токена частично решает проблему фиксированного масштаба.
Однако BPE оптимизирует статистическое сжатие, а не биологическую информативность, и это подтверждается прикладными наблюдениями. Повторяющиеся элементы генома (Alu, LINE, SINE — около 45% генома человека [8]) получают компактные токены за счёт высокой частотности. Уникальные регуляторные элементы остаются фрагментированными. Словарь фиксируется до обучения.

1.3.4 Ограничения статических подходов

Общая проблема всех трёх подходов состоит в том, что правила разбиения не зависят от контекста и остаются неизменными по всей последовательности, тогда как плотность функциональной информации в промоторе и в межгенном повторе отличается на порядки. Lindsey и др. [9] систематически сравнивают токенизаторы и показывают, что ни один статический метод не доминирует на всех задачах. Eapen [11] предлагает биологически обоснованные правила сегментации, однако они определяются вручную и не обучаются совместно с моделью.
Рассмотрим конкретный пример, связанный с k-мерной токенизацией и сайтами связывания транскрипционных факторов. Базы данных JASPAR 2024 содержат позиционные весовые матрицы для более чем 2000 TF с медианной шириной мотива 12–15 п.н. [19]: CTCF (19 п.н.), GATA1 (8 п.н.), SP1 (10 п.н.). При использовании 6-мерной токенизации без перекрытия (как в Nucleotide Transformer) 19-нуклеотидный CTCF-мотив разбивается на три–четыре токена, причём точка разреза определяется не биологической структурой мотива, а позицией в геноме. Один и тот же мотив, встретившийся на позиции p и на позиции $p + 3$, порождает разные последовательности токенов при идентичной функции — модель вынуждена заново выучивать функциональный паттерн для каждого фазового сдвига.
Для BPE-токенизатора характерна иная проблема: алгоритм оптимизирует частоту слияний, а не биологическую значимость. Геном человека содержит около $1{,}1 \times 10^6$ копий элементов Alu (семейство SINE, 300 п.н.) и более 5×10^5 копий LINE-1 (6 кб) [8], которые в совокупности составляют около 45% последовательности. Такая частота означает, что внутренние подпоследовательности Alu и LINE-1 — как правило, функционально инертные повторяющиеся участки — доминируют в корпусе обучения BPE и

получают непропорционально большую долю словаря. В результате токены, специализированные на регуляторных мотивах, вытесняются токенами для повторов; данный эффект количественно подтверждён в [9].

Различие в функциональной нагрузке хорошо отражается через оценки эволюционной консервативности: метод phastCons, основанный на филогенетической скрытой марковской модели по межвидовым выравниваниям [18], присваивает сайтам связывания TF в промоторной области значения 0,7–0,9, тогда как внутренние участки LINE-1 получают менее 0,1. Статический токенизатор не имеет доступа к данному сигналу: одинаковый бюджет токенов расходуется на функционально противоположные по информативности регионы.

Дополнительная трудность связана с переносимостью между видами. Словарь BPE, обученный на геноме человека, плохо обобщается на организмы с иным транспозонным ландшафтом: распределение k-граммов и частотности подстрок существенно различаются между видами с разным GC-составом и разной долей повторяющихся элементов. Nucleotide Transformer частично обходит данную проблему за счёт мультивидового обучения, однако ограничение фиксированного k сохраняется: граница токена по-прежнему не зависит от того, является ли данный участок частью консервативного мотива или находится внутри повторяющегося элемента.

1.4 Адаптивная и обучаемая токенизация

1.4.1 Адаптивная токенизация в NLP

Проблема фиксированной токенизации активно исследуется и в NLP. Для данной работы особенно релевантны четыре подхода.

Charformer [36] вводит Gradient-Based Subword Tokenization (GBST) — модуль мягкой токенизации, обучаемый совместно с моделью. GBST вычисляет взвешенную комбинацию группировок символов через обучаемые скоры. Границы токенов трудно интерпретировать из-за одноуровневой группировки без ограничения непересечения. Funnel Transformer [37] идёт другим путём — stride pooling постепенно сокращает длину, но коэффициент сжатия одинаков для всех частей входа. MegaByte [15] обрабатывает до 10^6 байт через разделение на локальный и глобальный Transformer с фиксированным разбиением на фрагменты, не адаптирующимся к

содержимому.

Byte Latent Transformer (BLT) [14] от Meta FAIR занимает отдельное место. Границы patch'ей определяются по энтропии предсказания следующего байта: там, где модель неуверена, разбиение мельче. Авторы показали, что на сопоставимом вычислительном бюджете такие адаптивные границы оказываются эффективнее фиксированных. Данный подход является наиболее близким к предлагаемой в работе идее в рамках NLP, хотя она разработана для текста и не использует предметно-специфические сигналы.

1.4.2 Адаптивная токенизация ДНК

В геномике аналогичные идеи появились позже, примерно в 2024–2025 годах. MxDNA [12] (NeurIPS 2024) реализует адаптивность через разреженную смесь свёрточных экспертов с деформируемыми свёртками: выбор эксперта определяет масштаб анализа. Авторы сообщают об улучшениях на ряде задач по сравнению с фиксированными токенизаторами, но механизм выбора не использует биологических приоров и не даёт явного контроля над границами. Принципиально: адаптивность MxDNA означает выбор масштаба анализа, то есть адаптацию к локальной сложности последовательности в смысле частотного состава — но не к её биологической аннотации. Модель не различает, находится ли текущая позиция внутри TFBS (transcription factor binding site) мотива или в межгенном повторе.

Наиболее близкий по механизму к нашему подходу класс методов вычисляет попарные оценки сходства между соседними токенами и сливает наиболее похожие пары. Это одноуровневая схема без рекурсии и без дифференцируемого DP, однако именно по принципу слияния она ближе всего к предлагаемому подходу.

Отдельную нишу занимают детерминистические подходы на основе аннотаций: сегментация по известным мотивам TF из JASPAR [19] даёт интерпретируемые токены, но жёстко зависит от полноты аннотаций и не адаптируется к последовательностям без покрытия базой данных. BioToken/BioFM [13] показывает, что даже простой учёт биологической структуры при построении токенов улучшает прикладное качество, что косвенно подтверждает гипотезу о необходимости биологически мотивированных границ.

1.4.3 Сравнительный анализ подходов

Для структурированного сравнения существующие подходы целесообразно рассматривать по нескольким осям: обучаемый или детерминистический механизм определения границ, наличие биологических приоров, число уровней иерархии и способ обеспечения дифференцируемости.

В рассмотренных работах не встречается комбинация всех четырёх свойств сразу: рекурсивное многоуровневое слияние, дифференцируемое ограничение непересечения через DP, интеграция биоприоров как обучаемого индуктивного смещения и температурный отжиг для минимизации разрыва обучение–инференс. Именно эту комбинацию мы предлагаем в главе 2.

Дополнительно в предлагаемой архитектуре вводится накопительное состояние токена при слиянии, что позволяет принимать решение не только по текущей паре соседей, но и с учётом истории предыдущих операций слияния. Для оценки практической состоятельности такого подхода в экспериментальной части отдельно контролируется качество сжатия относительно BPE: сравниваются token ratio (TR) и изменение бит на нуклеотид (ΔBPN) на одинаковой выборке.

1.5 Бенчмарки для оценки геномных языковых моделей

Для сравнительной оценки предлагаемого метода необходим бенчмарк, охватывающий задачи регуляторной геномики и позволяющий проводить сравнение с существующими архитектурами в единых условиях.

Genomic Benchmarks [38] — коллекция задач классификации (промоторы, энхансеры, транскрипционные факторы). Задачи относительно просты и не покрывают сценарии без дообучения и зондирования, но удобны для базового сравнения. BEND [39] добавляет более биологически значимые задачи: структура хроматина, эффекты мутаций, функциональная аннотация.

Wei и др. [40] провели масштабное сравнение DNA foundation models на расширенном наборе задач. Полученный результат показателен: ни одна модель не доминирует — разные архитектуры и токенизации лучше работают на разных задачах. Vishniakov и др. [10] пошли дальше и критически оценили саму парадигму предобучения: оно не всегда улучшает прикладные результаты по сравнению с обучением с нуля. Это указывает на

необходимость поиска альтернативных архитектурных решений, в том числе подходов адаптивной токенизации.

DART-Eval [16] — на данный момент один из наиболее полных бенчмарков для DNA LM на задачах регуляторной ДНК. Он включает пять групп задач:

1) обнаружение мотивов (без дообучения) — распознавание 1443 мотивов TF через likelihood scoring;
2) предсказание связывания TF — зондирование и дообучение;
3) предсказание доступности хроматина;
4) предсказание клеточно-специфичной регуляторной активности;
5) предсказание эффектов генетических вариантов (caQTLs, chromatin accessibility quantitative trait loci — варианты, влияющие на доступность хроматина; dsQTLs, DNase I sensitivity quantitative trait loci — варианты, влияющие на чувствительность к DNase I).

Использование данного бенчмарка для оценки адаптивной токенизации обусловлено тем, что его задачи сфокусированы именно на регуляторной ДНК — там, где адаптивная токенизация теоретически должна давать выигрыш за счёт более детального разрешения в функционально значимых мотивах. Авторы DART-Eval также показали, что существующие DNA LM не обеспечивают устойчивого преимущества над ab initio моделями (ChromBPNet) — пространство для архитектурных улучшений сохраняется.

1.6 Выводы по главе 1

Существующие геномные языковые модели в основном используют статическую токенизацию — посимвольную, k-мерную или BPE. Ни один из этих вариантов в явном виде не учитывает функциональную неоднородность генома.

Работы по обучаемой токенизации ДНК (MxDNA, MergeDNA и др.) решают отдельные аспекты, но пока не объединяют рекурсивное слияние, дифференцируемое DP и биологические приоры в единую архитектуру. Опыт NLP — прежде всего BLT — показывает, что адаптивные границы нередко работают лучше фиксированных, однако перенос этих идей в геномику с учётом предметных сигналов остаётся открытым.

DART-Eval обеспечивает адекватную базу для сравнительной оценки на задачах регуляторной геномики.

2 ОПИСАНИЕ ПРЕДЛАГАЕМОГО МЕТОДА

В настоящей главе описана архитектура адаптивного токенизатора ДНК-последовательностей. Метод основан на рекурсивном гейтированном слиянии с дифференцируемым динамическим программированием и обучается совместно с основной моделью на задаче предсказания следующего нуклеотида (NTP) на референсном геноме человека.

2.1 Общая архитектура

Метод включает последовательную обработку исходной цепочки нуклеотидов с рекурсивным объединением соседних элементов в составные токены, что переносит основную вычислительную нагрузку на более короткую последовательность. Выбор пар для слияния выполняется обучаемой функцией, оптимизируемой совместно с моделью. Формально схема содержит четыре последовательных этапа: инициализация представлений на уровне нуклеотидов; рекурсивное слияние соседних элементов с гейтированной оценкой; кодирование результата основной моделью на укороченной последовательности; декодирование обратно на уровень нуклеотидов для вычисления функции потерь NTP.

По сравнению с фиксированным разбиением на фрагменты (MegaByte [15]) метод отличается адаптивными границами. От одноуровневой мягкой токенизации (GBST в Charformer [36]) — рекурсивной схемой с ограничением непересечения через дифференцируемое DP. От разбиения по энтропии (BLT [14]) — использованием биологических приоров.

2.2 Инициализация представлений

2.2.1 Входная последовательность и матрица вложений

Входная ДНК-последовательность длины L:

$$S = (n_1, n_2, \ldots, n_L), \qquad n_i \in \{A, T, C, G\}. \tag{2.1}$$

Словарь включает канонические нуклеотиды, символ N и специальные токены $[PAD]$, $[MASK]$, $[BOS]$ — всего $|V| = 8$. Каждый входной символ

отображается в вектор размерности d через обучаемую матрицу $E \in \mathbb{R}^{|V| \times d}$:

$$e_v = E[v] \in \mathbb{R}^d. \tag{2.2}$$

Словарь существенно меньше типичных словарей NLP (порядка 10^4–10^5 токенов), поэтому основная выразительная способность представления переносится на последующие уровни слияния. Инициализацию матрицы вложений можно сделать биологически мотивированной: пурины (A, G) и пиримидины (T, C) образуют две группы, а комплементарные пары $(A \leftrightarrow T, G \leftrightarrow C)$ связаны Watson–Crick спариванием. На практике каждому нуклеотиду назначается вектор группы, к которому добавляется уникальное смещение и небольшой случайный шум для нарушения симметрии.

2.2.2 Позиционное кодирование

Используется Rotary Positional Embedding (RoPE) [41]: скалярное произведение двух закодированных позиций зависит только от относительного расстояния. Для рекурсивного слияния это свойство существенно, поскольку абсолютные позиции постепенно теряют роль, тогда как относительное положение соседей остаётся сигналом для принятия решения о слиянии на каждом уровне.

2.2.3 Контекстное обогащение

Начальные вложения содержат информацию только об одном нуклеотиде. Для расширения контекста перед конвейером слияний применяется каузальная одномерная свёртка с размером ядра 5:

$$\hat{x}_i^{(0)} = x_i^{(0)} + \mathrm{Conv1D}_{k=5}(\mathbf{X}^{(0)})_i. \tag{2.3}$$

Каузальность (дополнение нулями слева) нужна для совместимости с NTP. Параметров добавляется $5d^2$ — при $d = 256$ около 320 000, что пренебрежимо мало по сравнению с основной моделью.

2.2.4 Обработка reverse complement

ДНК является двуцепочечной молекулой, и многие функциональные элементы работают на обеих цепях. В связи с этим используются две стратегии: аугментация данных (с вероятностью $0{,}5$ заменяем последовательность на обратный комплемент) и опциональный

регуляризатор $\mathcal{L}_{\text{RC}}$, штрафующий расхождение оценок слияния между прямой и комплементарной цепью (подробнее в §2.6).

2.3 Гейтированная оценка границ

2.3.1 Функция оценки слияния

На каждом уровне рекурсии l для каждой соседней пары $(x_i^{(l)}, x_{i+1}^{(l)})$ оценка слияния складывается из компоненты сходства и контекстно-зависимого гейта.

Компонента сходства вычисляется через scaled dot-product с обучаемой проекцией:

$$s_{\text{sim},i}^{(l)} = \frac{(x_i^{(l)})^\top W_k^{(l)}\, x_{i+1}^{(l)}}{\sqrt{d}}, \tag{2.4}$$

где $W_k^{(l)} \in \mathbb{R}^{d\times d}$. Данная проекция делает оценку асимметричной, что методологически оправдано: ДНК-последовательность направлена ($5' \to 3'$), и порядок нуклеотидов биологически значим [25]. Кроме того, $W_k^{(l)}$ выполняет роль обучаемого метрического тензора для задачи слияния: она перенастраивает пространство признаков так, чтобы высокую оценку получали именно пары, которые целесообразно сливать в рамках NTP-цели, а не просто близкие по евклидовой или косинусной геометрии исходных вложений.

Гейт отражает контекстно-зависимую склонность к слиянию:

$$g_i^{(l)} = \sigma\Big((w_g^{(l)})^\top [x_i^{(l)}; x_{i+1}^{(l)}] + b_g^{(l)}\Big), \tag{2.5}$$

где σ — сигмоидная функция. Гейт выполняет роль, которую оценка сходства выполнить не может: он способен подавить слияние на границах кодонов или в регуляторных областях даже при высоком сходстве векторов соседей. Смещение $b_g^{(l)}$ инициализируется $-0{,}5$ — это создаёт начальное смещение к неслиянию и предотвращает чрезмерное сжатие на ранних итерациях.

Таким образом, $s_i^{(l)} = g_i^{(l)} \cdot s_{\text{sim},i}^{(l)}$.

2.3.2 Температурная модуляция

Для управления жёсткостью решений вводится температура $\tau^{(l)} > 0$:

$$s_i^{(l)} = g_i^{(l)} \cdot \frac{s_{\text{sim},i}^{(l)}}{\tau^{(l)}}. \tag{2.6}$$

Температура снижается по косинусной схеме от $\tau_{\text{max}} = 1{,}0$ до $\tau_{\text{min}} = 0{,}1$. Высокая температура соответствует мягким решениям, низкая — более жёстким, близким к бинарным. Данная схема сужает расхождение между мягким выбором при обучении и жёстким при инференсе.

2.3.3 Интеграция биологических приоров

Биологические приоры вводятся как дополнительные входы в гейт, а не как отдельная цель обучения.

Выбор phastCons и JASPAR обусловлен тем, что они дают разные типы сигнала. phastCons (phylogenetic hidden Markov model conservation scores) — профили консервативности по мультивидовым выравниваниям. Практически важно другое: резкий перепад $|c_i - c_{i+1}| \gg 0$ между соседними позициями — надёжный маркер функциональной границы, там кодирующий участок часто переходит в межгенную область или заканчивается один регуляторный элемент. JASPAR (open-access database of transcription factor binding profiles) содержит позиционные весовые матрицы для более 2000 факторов транскрипции [19]; присутствие мотива является прямым аргументом против разрезания участка на произвольных границах.

Для оценок консервативности (phastCons [18], $c_i \in [0, 1]$) формируется вектор из пяти признаков: значения c_i и c_{i+1}, их разность, минимум и среднее. Разрыв $|c_i - c_{i+1}|$ сигнализирует о возможной функциональной границе между регионами с разным эволюционным давлением.

Для мотивов JASPAR [19] аналогичный вектор включает индикаторы начала и конца мотива, число мотивов, перекрывающих позицию, и качество лучшего совпадения.

Расширенный гейт объединяет обучаемую и биологическую компоненты:

$$g_i^{(l)} = \sigma\Big((w_g^{(l)})^\top [x_i^{(l)}; x_{i+1}^{(l)}] + (w_c^{(l)})^\top \phi_i + (w_m^{(l)})^\top \psi_i + b_g^{(l)}\Big), \tag{2.7}$$

где ϕ_i и ψ_i — векторы признаков консервативности и мотивов (по 5 компонент каждый), $w_c^{(l)}$ и $w_m^{(l)}$ — обучаемые веса. Если аннотации отсутствуют (другой организм, нет BigWig/BigBed), модель использует только первый член — архитектура не зависит от наличия биоприоров.

2.4 Механизм рекурсивного слияния

2.4.1 Задача выбора пар

На каждом уровне нужно выбрать подмножество соседних пар для слияния, причём выбранные пары не должны пересекаться — иначе один токен будет участвовать в двух слияниях одновременно, что нарушает структуру последовательности:

$$M^{(l)} = \arg\max_{M} \sum_{i \in M} s_i^{(l)}, \qquad |M| = \lfloor r^{(l)} N^{(l)} \rfloor, \qquad \forall\, i, j \in M : |i - j| > 1, \tag{2.8}$$

где $r^{(l)}$ — целевая доля слияний на уровне l. Задача решается динамическим программированием на одномерной последовательности, однако жёсткий argmax делает этот шаг недифференцируемым.

2.4.2 Дифференцируемый выбор через dDP

При обучении жёсткий argmax заменяется на мягкий через log-semiring relaxation [17]. Вместо операции max используется softmax_β:

$$\text{softmax}_\beta(a, b) = \frac{1}{\beta} \log(\exp(\beta a) + \exp(\beta b)), \tag{2.9}$$

которая при $\beta \to \infty$ стремится к max.
DP-рекуррента принимает вид:

$$D[i, k] = \text{softmax}_\beta\Big(D[i-1, k],\ D[i-2, k-1] + s_i^{(l)}\Big), \tag{2.10}$$

где $D[i, k]$ — мягкий оптимальный score при i рассмотренных позициях и k выбранных парах. Мягкие веса слияния $\alpha_i^{(l)} \in [0, 1]$ извлекаются как производная $\partial D[N, K]/\partial s_i$, что интерпретируется как маргинальная вероятность включения позиции i в оптимальный набор. Вычислительная сложность составляет $O(N \cdot K)$ на уровень.
В качестве альтернативы рассматривается Straight-Through Estimator (STE) [42]: forward pass — жёсткий DP, backward — градиент через soft scores. Подход проще в реализации, но даёт смещённые градиенты.

2.4.3 Формирование объединённых представлений

Для учёта накопительного эффекта слияний каждому токену сопоставляется не только текущее представление $x_i^{(l)}$, но и состояние $a_i^{(l)}$ (на нулевом уровне $a_i^{(0)} = x_i^{(0)}$). Для каждой выбранной пары объединённое представление вычисляется MLP:

$$\tilde{x}_i^{(l+1)} = \mathrm{MLP}_{\mathrm{merge}}^{(l)}\Big([x_i^{(l)};\ x_{i+1}^{(l)};\ x_i^{(l)} \odot x_{i+1}^{(l)};\ a_i^{(l)};\ a_{i+1}^{(l)};\ a_i^{(l)} \odot a_{i+1}^{(l)}]\Big), \quad (2.11)$$

где $\odot$ — поэлементное произведение. Конкатенация сохраняет информацию обоих входов, произведение явно кодирует попарное взаимодействие. MLP: вход $6d$, скрытый $2d$, выход d, активация GELU [43]. Накопленное состояние обновляется как

$$\tilde{a}_i^{(l+1)} = \mathrm{LayerNorm}\Big(W_a^{(l)}[a_i^{(l)};\ a_{i+1}^{(l)};\ \tilde{x}_i^{(l+1)}]\Big). \quad (2.12)$$

Переход к следующему уровню строится через жёсткую компактификацию последовательности (в train и inference):

$$N^{(l+1)} = N^{(l)} - |\mathcal{M}_{\mathrm{hard}}^{(l)}|, \quad (2.13)$$

где для выбранных пар добавляются $(\tilde{x}_i^{(l+1)}, \tilde{a}_i^{(l+1)})$, а для невыбранных позиций — $(\mathrm{proj}(x_i^{(l)}), a_i^{(l)})$. Градиент в скоринговый модуль проходит по схеме жёсткий прямой / мягкий обратный через $\alpha_i^{(l)}$. Для скоринга на следующем уровне используется обогащённое состояние $\bar{x}_i^{(l)} = x_i^{(l)} + U_a^{(l)} a_i^{(l)}$.

2.5 Позиционное кодирование после слияния и декодирование

2.5.1 Позиционное кодирование спанов

После слияния каждый токен j покрывает непрерывный диапазон $[a_j, b_j]$ в исходной последовательности. RoPE частично ослабляется нелинейными MLP слияния — координаты исходных позиций перемешиваются с весами и теряют чёткую семантику. Поэтому перед основной моделью позиционная информация повторно внедряется явно.

Для каждого токена формируется вектор из шести признаков: начало спана a_j, конец b_j, длина ℓ_j, центр m_j, нормированные a_j/L и ℓ_j/L. Этот вектор пропускается через MLP. Дополнительно кодируется глубина

рекурсии, на которой сформирован токен, — через унитарное представление, проецируемое в $\mathbb{R}^d$.

2.5.2 Основная модель

Укороченная последовательность ($N \ll L$ токенов) обрабатывается каузальным Transformer: 6 слоёв, 8 голов, $d = 256$, FFN $4d = 1024$, pre-LN, RoPE на уровне позиций токенов. Самый дорогой компонент системы — основная модель с квадратичной сложностью по N — работает именно на сжатой последовательности.

2.5.3 Каузальный декодер с перекрёстным вниманием

Целевая функция определена на уровне нуклеотидов, поэтому необходимо восстановить представления длины L. При этом возникает следующая проблема: токен j со спаном $[a_j, b_j]$ несёт информацию обо всех нуклеотидах внутри, в том числе о «будущих» относительно позиции $t < b_j$. Прямое использование $\hat{z}_{m(t)}$ для предсказания n_t приводит к утечке информации, поэтому декодер должен явно исключать данный эффект.
Для каждой позиции t формируется вектор запроса

$$q_t = E[n_{t-1}] + P_{\text{dec}}[t], \tag{2.14}$$

где для $t = 1$ используется токен $[BOS]$. Проекция W_Q в базовой конфигурации отключена (тождественное преобразование) и рассматривается только в аблационном исследовании. Каузальная маска ограничивает attention токенами с $b_j < t$, полностью завершившимися до позиции t. Остаточная связь от сдвинутых вложений возвращает часть информации нуклеотидного уровня, которая могла быть потеряна при слиянии:

$$r_t^{\text{ctx}} = \text{CrossAttn}(q_t, \hat{Z}, \text{Mask}(t, \cdot)) + W_{\text{skip}} \cdot E[n_{t-1}]. \tag{2.15}$$

Чтобы снизить риск потери сигнала на ранних позициях спана, добавляется локальный авторегрессионный путь без доступа к будущему контексту:

$$u_t = \text{IntraDecoder}(u_{t-1}, E[n_{t-1}], \hat{z}_{j^-}), \tag{2.16}$$

где j^- — индекс последнего полностью завершённого токена ($b_{j^-} < t$). Итоговое состояние декодера:

$$r_t = r_t^{\text{ctx}} + W_u u_t. \tag{2.17}$$

На выходе формируются логиты по четырём нуклеотидам через линейный слой + softmax. Для длинных последовательностей ($L > 4096$) допускается упрощение глобального перекрёстного внимания с переходом к преимущественно локальному авторегрессионному режиму (лёгкий GRU).

2.6 Функция потерь

2.6.1 Основная функция потерь

Основным сигналом служит предсказание следующего нуклеотида:

$$\mathcal{L}_{\text{NTP}} = -\frac{1}{|T_{\text{valid}}|} \sum_{t \in T_{\text{valid}}} \log P(n_t \mid n_{<t}), \tag{2.18}$$

где T_{valid} исключает позиции с N и $[PAD]$. Токенизатор не имеет отдельной внешней супервизии — границы токенов обучаются ровно в той мере, в которой они помогают основной модели и декодеру лучше решать NTP.

2.6.2 Регуляризаторы

К основной функции потерь добавляются четыре вспомогательных компонента.

Регуляризатор сжатия штрафует отклонение коэффициента сжатия от целевого. В обучении используется мягкая оценка через маргиналы $\alpha_i^{(l)}$:

$$\mathcal{L}_{\text{compress}} = \sum_{l=1}^{L_{\max}} \left(\hat{r}_{\text{soft}}^{(l)} - r_{\text{target}}^{(l)} \right)^2, \quad \hat{r}_{\text{soft}}^{(l)} = \frac{1}{N^{(l)} - 1} \sum_{i=1}^{N^{(l)}-1} \alpha_i^{(l)}. \tag{2.19}$$

Без данного члена модель может коллапсировать в режим «почти ничего не сливать», что существенно снижает эффект сжатия.

Энтропийная регуляризация поощряет исследование пространства решений на ранних стадиях — предотвращает преждевременный коллапс решений о слиянии в тривиальные паттерны. Используется только в прогревочной фазе, затем обнуляется.

Регуляризация RC-согласованности штрафует расхождение оценок слияния между прямой и комплементарной цепью — биологическая пара должна сегментироваться согласованно:

$$\mathcal{L}_{\text{RC}} = \frac{1}{|\mathcal{P}|} \sum_{(i,\text{RC}(i))\in\mathcal{P}} \left(s_i^{(l)} - s_{\text{RC}(i)}^{(l)} \right)^2 . \tag{2.20}$$

Регуляризатор разнообразия спанов штрафует низкую дисперсию длин. Если все спаны одной длины — токенизация фактически становится фиксированной, и смысл всего механизма теряется.

2.6.3 Итог

$$\mathcal{L} = \mathcal{L}_{\text{NTP}} + \lambda_{\text{comp}}\mathcal{L}_{\text{compress}} + \lambda_{\text{ent}}\mathcal{L}_{\text{ent}} + \lambda_{\text{RC}}\mathcal{L}_{\text{RC}} + \lambda_{\text{div}}\mathcal{L}_{\text{div}}. \tag{2.21}$$

Коэффициенты λ меняются по расписанию: в фазе прогрева (первые 10% шагов) $\lambda_{\text{comp}} = 1{,}0$, $\lambda_{\text{ent}} = 0{,}1$, $\lambda_{\text{div}} = 0{,}01$, $\lambda_{\text{RC}} = 0{,}1$. В основной фазе λ_{ent} обнуляется, λ_{comp} снижается до $0{,}1$ по косинусной схеме. В фазе ужесточения всё фиксируется.

2.7 Стратегия обучения

2.7.1 Оптимизатор

AdamW [44] ($\beta_1 = 0{,}9$, $\beta_2 = 0{,}98$, регуляризация весов $0{,}01$), пиковая скорость обучения 3×10^{-4}, линейный прогрев 2000 шагов, косинусное затухание до 3×10^{-5}, ограничение нормы градиента $1{,}0$, смешанная точность bf16.

2.7.2 Поэтапное обучение

Прямое совместное обучение основной модели и конвейера слияний с нулевого шага нестабильно: конвейер слияний принимает решения на основе ещё не информативных вложений. Поэтому обучение разбито на три фазы.

Фаза 1 (прогрев основной модели, шаги 0–5 000): конвейер слияний заморожен, слияния отключены. Основная модель обучается как посимвольная модель и получает осмысленные вложения до активации конвейера слияний.

Фаза 2 (совместное обучение, шаги 5 000–90 000): конвейер слияний разморожен. Температурный отжиг и рост β активированы. Коэффициенты

λ по расписанию (§2.6).

Фаза 3 (ужесточение, шаги 90 000–100 000): финальный отжиг до почти дискретных решений. Скорость обучения находится в нижней части косинусного затухания.

2.7.3 Подготовка данных

Референсный геном CHM13 [21]; chr8 — тест, chr9 — валидация, по протоколу HyenaDNA [1]. Из обучающих хромосом берутся случайные фрагменты длины L; регионы с $> 50\%$ символов N пропускаются. Аугментация обратным комплементом — с вероятностью $0{,}5$. Оценки консервативности загружаются через BigWig (phastCons [18]), аннотации мотивов — через BigBed (JASPAR [19]). Размер пакета 64, накопление градиентов $\times 2$ (эффективный размер пакета 128).

2.8 План экспериментальной оценки

2.8.1 Базовые модели

Для сравнения: Char-Transformer (посимвольный), BPE-Transformer (словарь 4096), Fixed-kmer-Transformer ($k = 6$), Char-Mamba (SSM), Charformer [36]. Все обучаются на тех же данных с сопоставимым числом параметров ($\pm 10\%$).

2.8.2 Абляционное исследование

Отключаем по одному компоненту: биологические приоры, температурный отжиг, позиционное кодирование спанов, произведение Адамара в МЛП слияния, накопительное состояние a_i, dDP (замена на STE), проекция запросов W_Q (вкл./выкл.), декодер с перекрёстным вниманием (замена на МЛП), контекстуализатор, поэтапное обучение.

2.8.3 Метрики

Предобучение: перплексия NTP (мягкий/жёсткий режимы), бит на нуклеотид (BPN), коэффициент токенизации TR $= N/L$, коэффициент сжатия CR $= 1 - N/L$, энтропия решений о слиянии, зазор обучение-инференс, а также сравнение с BPE на той же выборке: $\mathrm{TR}_{\mathrm{adapt}} - \mathrm{TR}_{\mathrm{BPE}}$ и ΔBPN.

Приемлемым считается режим, в котором $\mathrm{TR}_{\mathrm{adapt}}$ не хуже BPE более чем на $0{,}05$, а ухудшение ΔBPN не превышает $0{,}02$.

Прикладные задачи: DART-Eval [16] (без дообучения, зондирование, дообучение). Дообучение: основная модель заморожена или LoRA rank 8, линейный классификатор, 10 эпох, скорость обучения 10^{-4}. Конвейер слияний при дообучении не перенастраивается. Дополнительно: variant effect prediction (ClinVar [45], база клинически интерпретированных генетических вариантов), promoter detection (EPDnew [46], Eukaryotic Promoter Database), splice site prediction (GENCODE [24], референсная аннотация генов и транскриптов).

2.8.4 Анализ выученной токенизации

Для проверки биологической гипотезы: анализ обогащения (пересечение границ с аннотациями GENCODE [24] и ENCODE cCREs [23], кандидатные цис-регуляторные элементы), оценка биологической согласованности (совпадение с экзон-интронными границами и границами мотивов TF), корреляция длины спана с оценкой консервативности, визуализация в браузере генома.

2.9 Вычислительная сложность

Основные компоненты: матрица вложений — $O(Ld)$; оценка слияний — $O(N^{(l)}d^2)$ на уровень; dDP — $O(N^{(l)}K^{(l)})$ на уровень; МЛП слияния с накопительным состоянием — $O(N^{(l)} \cdot 6d \cdot 2d)$ на уровень; основная модель (Transformer) — $O(N^2d)$; декодер с перекрёстным вниманием — $O(LNd)$. Суммарно около 19,5M параметров (основная модель $\sim$15M, конвейер слияний $\sim$3M, декодер $\sim$1,5M). При этом самый дорогой компонент (основная модель) работает на сжатой последовательности $N \ll L$.

2.10 Выводы по главе 2

Log-semiring relaxation — не единственный способ дифференцировать динамическое программирование, но для задачи выбора непересекающихся пар он предпочтительнее REINFORCE-оценок: градиент получается плотным, а температурный отжиг от $\tau_{\text{max}} = 1{,}0$ до $\tau_{\text{min}} = 0{,}1$ позволяет планомерно сужать зазор между мягким обучением и жёстким инференсом. Каузальный декодер с перекрёстным вниманием и маской $b_j < t$ позволяет сохранить вычислительную экономию основной модели ($N \ll L$) при обучении посимвольно без утечки информации из будущего. В

базовой конфигурации дополнительная проекция запросов не используется; в аблационном исследовании будет оценена целесообразность её включения с точки зрения соотношения прироста точности и дополнительного параметрического бюджета.

Составная функция потерь с четырьмя регуляризаторами и трёхфазная стратегия обучения представляют собой практические решения, направленные на стабилизацию совместного обучения токенизатора и основной модели. При этом не исключено, что часть регуляризаторов является избыточной для данной архитектуры, что составляет один из ключевых вопросов, подлежащих проверке в аблационном исследовании.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. HyenaDNA: Long-Range Genomic Sequence Modeling at Single Nucleotide Resolution / E. Nguyen [et al.] // Advances in Neural Information Processing Systems. — 2024. — Vol. 36.
2. DNABERT-2: Efficient Foundation Model and Benchmark for Multi-Species Genome / Z. Zhou [et al.] // arXiv preprint arXiv:2306.15006. — 2024. — arXiv:2306.15006.
3. Caduceus: Bi-Directional Equivariant Long-Range DNA Sequence Modeling / Y. Schiff [et al.]. — 06/2024. — DOI: 10.48550/arXiv.2403.03234. — eprint: 2403.03234 (q-bio).
4. Nucleotide Transformer: Building and Evaluating Robust Foundation Models for Human Genomics / H. Dalla-Torre [et al.] // Nature Methods. — 2025. — Vol. 22, no. 2. — P. 287–297. — DOI: 10.1038/s41592-024-02523-z.
5. Sequence Modeling and Design from Molecular to Genome Scale with Evo / E. Nguyen [et al.] // Science. — 2024. — Vol. 386, no. 6723. — eado9336. — DOI: 10.1126/science.ado9336.
6. Genomic Language Models: Opportunities and Challenges / G. Benegas [et al.]. — 09/2024. — DOI: 10.48550/arXiv.2407.11435. — eprint: 2407.11435 (q-bio).
7. Sennrich R., Haddow B., Birch A. Neural Machine Translation of Rare Words with Subword Units // Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (ACL). — 2016. — P. 1715–1725. — DOI: 10.18653/v1/P16-1162.
8. Initial Sequencing and Analysis of the Human Genome / E. S. Lander, L. M. Linton, B. Birren, [et al.] // Nature. — 2001. — Vol. 409, no. 6822. — P. 860–921. — DOI: 10.1038/35057062.
9. The Impact of Tokenizer Selection in Genomic Language Models / L. M. Lindsey [et al.] // Bioinformatics. — 2025. — Vol. 41, no. 9. — btaf456. — DOI: 10.1093/bioinformatics/btaf456.

10. Genomic Foundationless Models: Pretraining Does Not Promise Performance / K. Vishniakov, K. Viswanathan, A. Medvedev, [et al.]. — 2024. — DOI: 10.1101/2024.12.18.628606. — bioRxiv: 2024.12.18.628606.

11. Eapen B. R. Genomic Tokenizer: Toward a Biology-Driven Tokenization in Transformer Models for DNA Sequences. — 2025. — DOI: 10.1101/2025.04.02.646836.

12. Model Decides How to Tokenize: Adaptive DNA Sequence Tokenization with MxDNA / L. Qiao [et al.] // Advances in Neural Information Processing Systems (NeurIPS). Vol. 37. — 2024.

13. BioToken and BioFM — Biologically-Informed Tokenization Enables Accurate and Efficient Genomic Foundation Models / K. Vishniakov [et al.]. — 2025. — DOI: 10.1101/2025.03.27.645711.

14. Byte Latent Transformer: Patches Scale Better Than Tokens / A. Pagnoni, S. Ram, G. Gupta, [et al.]. — 12/2024. — arXiv: 2412.09871. — Meta FAIR; arXiv:2412.09871.

15. MEGABYTE: Predicting Million-byte Sequences with Multiscale Transformers / L. Yu [et al.]. — 2023. — arXiv: 2305.07185. — arXiv:2305.07185.

16. DART-eval: A Comprehensive DNA Language Model Evaluation Benchmark on Regulatory DNA / A. Patel [et al.]. — 2025. — arXiv: 2412.05430 [cs.LG].

17. Mensch A., Blondel M. Differentiable Dynamic Programming for Structured Prediction and Attention // Proceedings of the 35th International Conference on Machine Learning (ICML). Vol. 80. — PMLR, 2018. — P. 3462–3471. — (Proceedings of Machine Learning Research).

18. Evolutionarily Conserved Elements in Vertebrate, Insect, Worm, and Yeast Genomes / A. Siepel [et al.] // Genome Research. — 2005. — Vol. 15, no. 8. — P. 1034–1050. — DOI: 10.1101/gr.3715005.

19. JASPAR 2024: 20th Anniversary of the Open-Access Database of Transcription Factor Binding Profiles / I. Rauluseviciute [et al.] // Nucleic Acids Research. — 2024. — Vol. 52, no. D1. — P. D174–D182. — DOI: 10.1093/nar/gkad804.

20. PyTorch: An Imperative Style, High-Performance Deep Learning Library / A. Paszke, S. Gross, F. Massa, [et al.]. — 2019. — arXiv: 1912.01703.

21. The Complete Sequence of a Human Genome / S. Nurk [et al.] // Science. — 2022. — Vol. 376, no. 6588. — P. 44–53. — DOI: 10.1126/science.abj6987.

22. Schoenfelder S., Fraser P. Long-Range Enhancer–Promoter Contacts in Gene Expression Control // Nature Reviews Genetics. — 2019. — Vol. 20, no. 8. — P. 437–455. — DOI: 10.1038/s41576-019-0128-0.

23. ENCODE Project Consortium. An Expanded Registry of Candidate Cis-Regulatory Elements for Studying Transcriptional Regulation // Nature. — 2024. — Vol. 625. — P. 857–867. — DOI: 10.1038/s41586-024-07105-6.

24. GENCODE Reference Annotation for the Human and Mouse Genomes / A. Frankish [et al.] // Nucleic Acids Research. — 2019. — Vol. 47, no. D1. — P. D766–D773. — DOI: 10.1093/nar/gky955.

25. Rosenberg M. S., Subramanian S., Kumar S. Patterns of Transitional Mutation Biases Within and Among Mammalian Genomes // Molecular Biology and Evolution. — 2003. — Vol. 20, no. 6. — P. 988–993. — DOI: 10.1093/molbev/msg113.

26. Large language models for bioinformatics / W. Ruan [et al.] // Quantitative Biology. — 2025. — Vol. 14, no. 1. — DOI: 10.1002/qub2.70014.

27. Attention Is All You Need / A. Vaswani [et al.] // Advances in Neural Information Processing Systems. Vol. 30. — Curran Associates, Inc., 2017.

28. DNABERT: Pre-Trained Bidirectional Encoder Representations from Transformers Model for DNA-language in Genome / Y. Ji [et al.] // Bioinformatics. — 2021. — Vol. 37, no. 15. — P. 2112–2120. — DOI: 10.1093/bioinformatics/btab083.

29. DNA Language Model GROVER Learns Sequence Context in the Human Genome / M. Sanabria [et al.] // Nature Machine Intelligence. — 2024. — Vol. 6. — P. 911–919. — DOI: 10.1038/s42256-024-00872-0.

30. Gu A., Dao T. Mamba: Linear-Time Sequence Modeling with Selective State Spaces. — 2023. — arXiv: 2312.00752.

31. Genome Modelling and Design across All Domains of Life with Evo 2 / E. Nguyen, M. Poli, [et al.]. — 2025. — arXiv: 2501.09718.

32. HybriDNA: A Hybrid Transformer-Mamba2 Long-Range DNA Language Model / M. Ma [et al.]. — 02/2025. — DOI: 10.48550/arXiv.2502.10807. — eprint: 2502.10807 (cs).

33. Dao T., Gu A. Transformers Are SSMs: Generalized Models and Efficient Algorithms Through Structured State Space Duality. — 2024. — arXiv: 2405.21060. — Mamba-2.

34. AlphaGenome: Advancing Regulatory Variant Effect Prediction with a Unified DNA Sequence Model / Ž. Avsec [et al.]. — 2025. — DOI: 10.1101/2025.06.25.661532.

35. Chen Z., Wei L., Gao G. Foundation models for bioinformatics // Quantitative Biology. — 2024. — Vol. 12, no. 4. — P. 339–344. — DOI: 10.1002/qub2.69.

36. Charformer: Fast Character Transformers via Gradient-based Subword Tokenization / Y. Tay, V. Q. Tran, S. Ruder, [et al.] // International Conference on Learning Representations (ICLR). — 2022.

37. Funnel-Transformer: Filtering out Sequential Redundancy for Efficient Language Processing / Z. Dai [et al.] // Advances in Neural Information Processing Systems (NeurIPS). Vol. 33. — 2020.

38. Genomic Benchmarks: A Collection of Datasets for Genomic Sequence Classification / K. Grešová [et al.] // BMC Genomic Data. — 2023. — Vol. 24, no. 1. — P. 25. — DOI: 10.1186/s12863-023-01123-8.

39. BEND: Benchmarking DNA Language Models on Biologically Meaningful Tasks / W. Tang [et al.] // arXiv preprint arXiv:2311.12570. — 2024. — arXiv:2311.12570.

40. Benchmarking DNA Foundation Models for Genomic and Genetic Tasks / Z. Wei [et al.] // Nature Communications. — 2025. — Vol. 16. — P. 876. — DOI: 10.1038/s41467-025-65823-8.

41. RoFormer: Enhanced Transformer with Rotary Position Embedding / J. Su [et al.]. — 2021. — arXiv: 2104.09864.

42. Bengio Y., Léonard N., Courville A. Estimating or Propagating Gradients Through Stochastic Neurons for Conditional Computation. — 2013. — arXiv: 1308.3432.

43. Hendrycks D., Gimpel K. Gaussian Error Linear Units (GELUs). — 2016. — arXiv: 1606.08415.

44. Loshchilov I., Hutter F. Decoupled Weight Decay Regularization // International Conference on Learning Representations (ICLR). — 2019. — arXiv:1711.05101.

45. ClinVar: Improving Access to Variant Interpretations and Supporting Evidence / M. J. Landrum, J. M. Lee, G. R. Riley, [et al.] // Nucleic Acids Research. — 2018. — Vol. 46, no. D1. — P. D1062–D1067. — DOI: 10.1093/nar/gkx1153.

46. The Eukaryotic Promoter Database: Expansion of EPDnew and New Promoter Analysis Tools / R. Dreos [et al.] // Nucleic Acids Research. — 2015. — Vol. 43, no. D1. — P. D92–D96. — DOI: 10.1093/nar/gku1111.

47. Tokenization and Deep Learning Architectures in Genomics: A Comprehensive Review / J. Clauwaert [et al.] // Computational and Structural Biotechnology Journal. — 2025. — DOI: 10.1016/j.csbj.2025.07.038.

48. authors A. DNAChunker: Learnable Tokenization for DNA Language Models. — 01/2026. — arXiv: 2601.03019. — arXiv:2601.03019.

49. MergeDNA: Context-Aware Genome Modeling with Dynamic Tokenization through Token Merging / Z. Liu [et al.] // Proceedings of the AAAI Conference on Artificial Intelligence. — 2026. — DOI: 10.1609/aaai.v40i1.37032. — AAAI 2026, Oral.

50. authors A. EvoLen: Evolution-Guided Tokenization for DNA Language Model. — 04/2026. — arXiv: 2604.08698. — arXiv:2604.08698.

51. authors A. DNAMotifTokenizer: Towards Biologically Informed Tokenization of Genomic Sequences. — 12/2025. — arXiv: 2512.17126. — arXiv:2512.17126.

52. authors A. PatchDNA: A Flexible and Biologically-Informed Alternative to Tokenization for DNA. — 2026. — DOI: 10.1101/2025.11.28.691095. — ICLR 2026.

53. authors A. Guided Tokenization and Domain Knowledge Enhance Genomic Language Models' Performance. — 02/2026. — DOI: 10.64898/2026.02.16.706213.

54. Evolution of the Germline Mutation Rate across Vertebrates / L. A. Bergeron, S. Besenbacher, J. Zheng, [et al.] // Nature. — 2023. — Vol. 615, no. 7951. — P. 285–291. — DOI: 10.1038/s41586-023-05752-y.

55. Ho J., Jain A., Abbeel P. Denoising Diffusion Probabilistic Models // Advances in Neural Information Processing Systems. Vol. 33. — 2020. — P. 6840–6851. — arXiv:2006.11239.

56. Structured Denoising Diffusion Models in Discrete State-Spaces / J. Austin [et al.] // Advances in Neural Information Processing Systems. Vol. 34. — 2021. — P. 17981–17993. — Also known as D3PM.

57. DiscDiff: Latent Diffusion Model for DNA Sequence Generation / Z. Li [et al.]. — 2024. — arXiv: 2402.06079.

58. Dirichlet Diffusion Score Model for Biological Sequence Generation / P. Avdeyev [et al.] // Proceedings of the 40th International Conference on Machine Learning. Vol. 202. — PMLR, 2023. — P. 1276–1301. — (Proceedings of Machine Learning Research).

59. Designing DNA with Tunable Regulatory Activity Using Discrete Diffusion / A. Sarkar [et al.] // bioRxiv. — 2024. — DOI: 10.1101/2024.05.23.595630.

60. Accelerating the Machine Learning Lifecycle with MLflow / M. A. Zaharia, A. Chen, [et al.] // IEEE Data Eng. Bull. — 2018. — Vol. 41. — P. 39–45.

61. Evolutionary-Scale Prediction of Atomic-Level Protein Structure with a Language Model. — DOI: 10.1126/science.ade2574. — Science, 2023.